CODERHOUSE

Noviembre 2026

Data Science II:
Machine Learning para la Ciencia de Datos
Diplomatura

Entrega N°1

Nombre del Proyecto: Modelado Predictivo y Enriquecimiento Biológico en Adopción de Mascotas

Diego Videla Silva
Comisión 96160



Tabla de contenido

1.- MOTIVACIÓN Y AUDIENCIA 3

Motivación: 3
Audiencia: 3
Preguntas / hipótesis: 3

2.- INFORMACIÓN SOBRE LAS FUENTES DE DATOS Y PROCESAMIENTO (ETL) 4

2.1.- Dataset original (Kaggle): 4
2.2.- Enriquecimiento biológico desde APIs externas (The Dog API / The Cat API): 6
2.3.- Proceso de integración (Merge), limpieza semántica con IA y bifurcación en Data Marts: 7

3.- ANÁLISIS DE HIPÓTESIS Y RESULTADOS 8

3.1.- Hipótesis 1: Esperanza de vida biológica vs. Velocidad de adopción 8
3.2.- Hipótesis 2: Impacto visual (Volumen de fotografías) vs. Velocidad de adopción 9
3.3.- Hipótesis 3: Preferencia de tamaño (Peso genético) vs. Velocidad de adopción 11
3.4.- Hipótesis 4: Factor edad al ingreso (Punto de quiebre) vs. Velocidad de adopción 12

1.- Motivación y audiencia

Motivación:

La sobrepoblación en refugios y centros de rescate animal es un desafío logístico y de bienestar crítico. Predecir qué animales tardarán más en ser adoptados permite a las organizaciones asignar recursos de marketing de manera eficiente y gestionar su capacidad instalada. Este proyecto analiza un registro transaccional de mascotas en adopción, cruzando variables de presentación (fotos, edad, color) con datos biológicos reales obtenidos mediante una API externa (esperanza de vida, temperamento, tamaño promedio según raza). El objetivo es identificar los principales predictores de la velocidad de adopción (medida en días) para optimizar las estrategias de rescate y ubicación.

Audiencia:

Dirigido a roles ejecutivos de fundaciones animalistas, directores logísticos de refugios, estrategas de marketing de ONG y médicos veterinarios enfocados en bienestar animal y medicina poblacional.

Preguntas / hipótesis:

1 - El impacto de la biología (API): ¿Los perros y gatos de razas con mayor expectativa de vida biológica promedio (extraída de la API) son adoptados más rápido que las razas de vida corta?
2 - El impacto visual: ¿El volumen de fotografías en el perfil de una mascota acelera estadísticamente su adopción, neutralizando factores como la edad avanzada?
3 - Preferencia de tamaño: ¿Existe un sesgo de adopción medible hacia los animales genéticamente más pequeños (según la API) frente a razas de tamaño grande o gigante?
4 - Factor edad al ingreso: ¿Cuál es el punto de quiebre (en meses de edad) donde la probabilidad de adopción temprana cae drásticamente?

2.- Información sobre las fuentes de datos y procesamiento (ETL)

2.1.- Dataset original (Kaggle):

La primera fuente corresponde al registro transaccional de mascotas en adopción (dataset/AdopcionMascotas.csv), complementado por el diccionario puente de etiquetas de razas (dataset/BreedLabels.csv) provisto por Kaggle. El dataset principal está compuesto por 14.993 registros y 24 columnas (19 variables de tipo int64, 1 de tipo float64 y 4 de tipo str), con un uso de memoria de 2.7 MB.

Diccionario de columnas del dataset transaccional:

Columna original	Traducción	Descripción breve	Non-Null	Dtype
Type	Tipo	Especie de la mascota (1 = Perro, 2 = Gato).	14993	int64
Name	Nombre	Nombre de la mascota.	13728	str
Age	Edad	Edad al ingreso en meses.	14993	int64
Breed1	Raza principal	ID numérico de la raza principal.	14993	int64
Breed2	Raza secundaria	ID de segunda raza, si es mestiza.	14993	int64
Gender	Sexo	Sexo de la mascota.	14993	int64
Color1 / 2 / 3	Color 1, 2 y 3	Colores del pelaje de la mascota.	14993	int64
MaturitySize	Tamaño adulto	Tamaño que alcanzará de adulto.	14993	int64
FurLength	Largo del pelaje	Longitud del pelo.	14993	int64
Vaccinated	Vacunado	Indica si está vacunada.	14993	int64

Dewormed	Desparasitado	Indica si está desparasitada.	14993	int64
Sterilized	Esterilizado	Indica si está esterilizada.	14993	int64
Health	Salud	Estado de salud general.	14993	int64
Quantity	Cantidad	Número de mascotas en la publicación.	14993	int64
Fee	Tarifa	Costo de la adopción.	14993	int64
State	Estado/Región	Ubicación geográfica de la mascota.	14993	int64
RescuerID	ID rescatista	Identificador de quien la rescató.	14993	str
VideoAmt	Cant. videos	Videos incluidos en la publicación.	14993	int64
Description	Descripción	Texto descriptivo de la mascota.	14980	str
PetID	ID mascota	Identificador único de la mascota.	14993	str
PhotoAmt	Cant. fotos	Fotos incluidas en la publicación.	14993	float64
AdoptionSpeed	Velocidad adopción	Días hasta adopción codificados (0 a 4).	14993	int64



2.2.- Enriquecimiento biológico desde APIs externas (The Dog API / The Cat API):

Para trascender el análisis transaccional básico, el dataset estático del refugio se enriqueció consumiendo dos servicios web REST públicos: The Dog API (https://api.thedogapi.com/v1/breeds) y The Cat API (https://api.thecatapi.com/v1/breeds). La integración de estas APIs permitió extraer la "verdad biológica" de los animales de raza pura (específicamente su esperanza de vida y peso estructural promedio). Cruzar la data logística con esta genética estandarizada fue clave para evaluar, con rigor científico, si la longevidad o el tamaño físico influyen realmente en las decisiones de los adoptantes.

Diccionario de claves JSON de respuesta de las APIs (Dog / Cat):

Key original	Traducción	Descripción breve	Tipo
id	Identificador	Identificador único de la raza.	str
name	Nombre	Nombre de la raza (renombrado a BreedName).	str
species_id	ID de especie	Identificador de la especie (perro o gato).	str
life_span	Esperanza de vida	Rango de años de vida de la raza.	str
temperament	Temperamento	Rasgos de carácter separados por comas.	str
origin	Origen	País de origen de la raza.	str
country_codes	Códigos de país	Código(s) ISO del país de origen.	str
description	Descripción	Descripción general de la raza.	str
bred_for	Criado para	Propósito original de la raza.	str / null
breed_group	Grupo de raza	Grupo al que pertenece la raza.	str

weight	Peso	Peso imperial y métrico en objeto anidado.	dict
height	Altura	Altura imperial y métrica en objeto anidado.	dict
image	Imagen	Datos de la imagen: id, url, width y height.	dict

2.3.- Proceso de integración (Merge), limpieza semántica con IA y bifurcación en Data Marts:

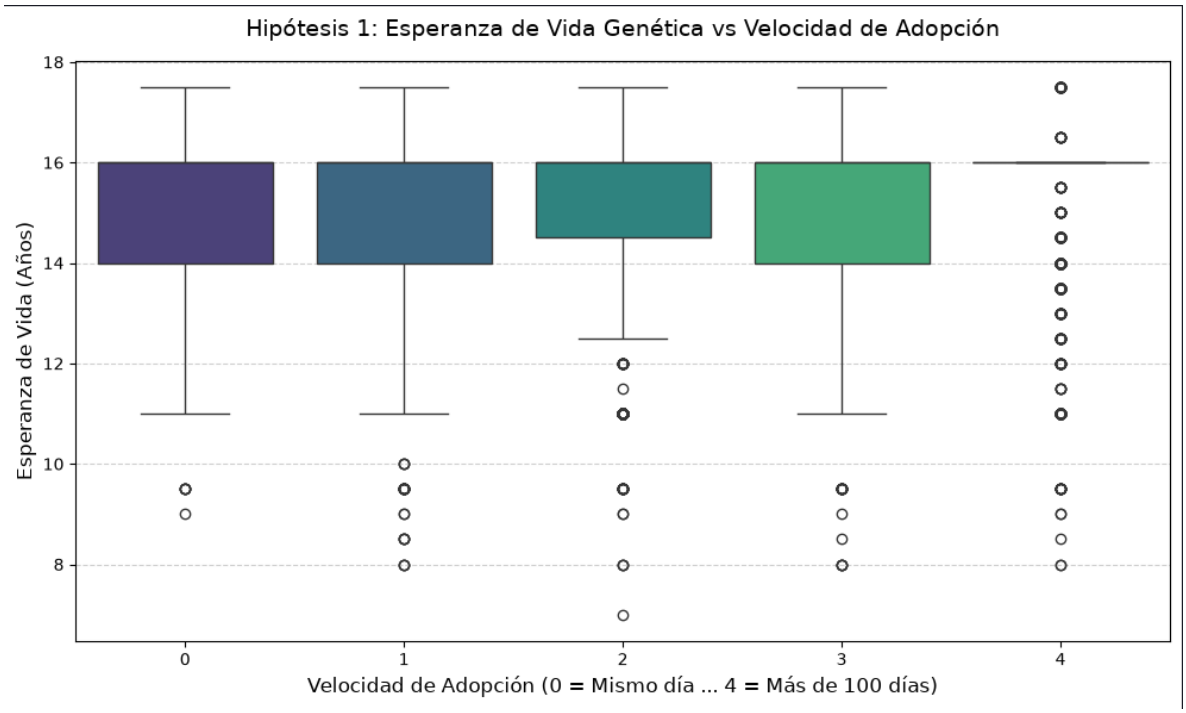
La construcción de la base analítica se ejecutó mediante un flujo de ingeniería de datos en cuatro etapas:
1. Doble Merge Inicial: Unión de la tabla transaccional (df_mascotas) con el diccionario puente (BreedLabels.csv), y cruce con el registro maestro biológico (df_biologia) generando un total de 14.994 filas.
2. Diagnóstico Inicial de Nulos y Fuzzy String Matching: 12.582 registros (83.9%) quedaron con biología nula (NaN en life_span), rescatando inicialmente solo 2.412 registros con genética completa. Para identificar los errores de tipificación, se ejecutó un algoritmo de Fuzzy String Matching con difflib.
3. Resolución Semántica de Entidades con Agente de IA (LLM): Dado que difflib es ciego a la biología, se diseñó un prompt especializado con reglas clínicas estrictas para auditar las sugerencias y conservar únicamente equivalencias genéticas puras (ej. "Domestic Short Hair": "Domestic Shorthair").
4. Impacto del Rescate Semántico y Bifurcación en Data Marts: Al aplicar las 22 correcciones clínicas y re-ejecutar el merge, la muestra con genética completa aumentó de 2.412 a 7.834 registros (52.2% del dataset total). Por rigor estadístico, el dataset se dividió en dos Data Marts especializados: df_final_full (14.994 registros) para variables que no dependen de la pureza racial, y df_final_razas (7.834 registros) exclusivo para razas puras.

3.- Análisis de hipótesis y resultados

3.1.- Hipótesis 1: Esperanza de vida biológica vs. Velocidad de adopción

Pregunta: ¿Los perros y gatos de razas con mayor expectativa de vida biológica promedio son adoptados más rápido que las razas de vida corta?
Procesamiento analítico: Utilizando el Data Mart biológico, se implementó una función parser con expresiones regulares para transformar los rangos de texto de la columna life_span en un valor numérico continuo promedio (life_span_num), cruzándolo luego contra las 5 categorías ordinales de AdoptionSpeed.

Velocidad de Adopción (0 a 4)	Esperanza de Vida Promedio (Años)
0 (Mismo día)	14.92 años
1 (1 a 7 días)	15.04 años
2 (8 a 30 días)	15.14 años
3 (31 a 90 días)	14.95 años
4 (Más de 100 días / No adoptado)	15.35 años



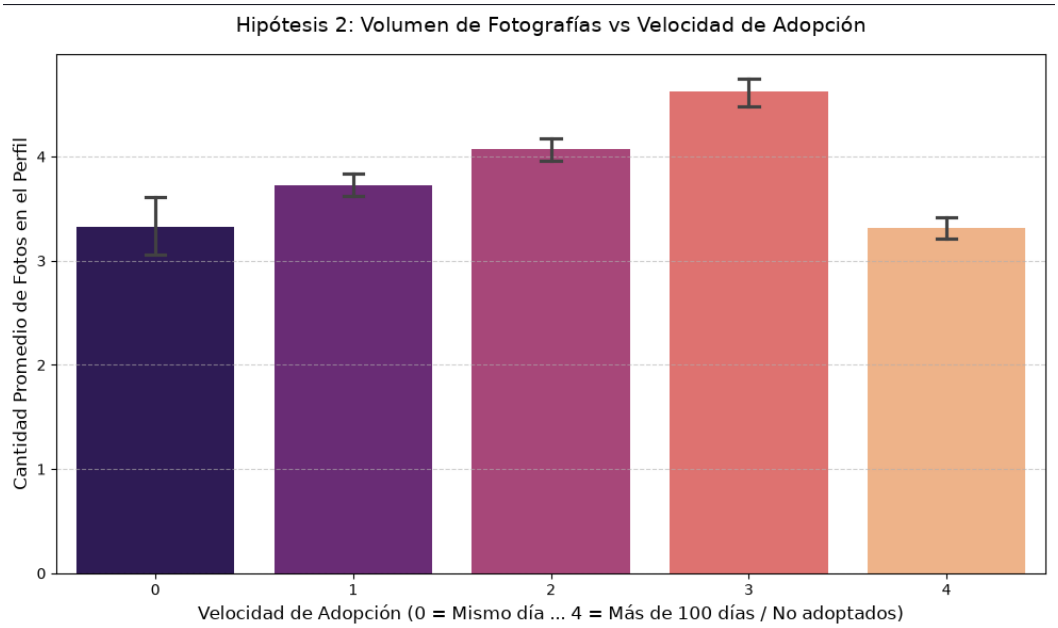
Conclusiones de la Hipótesis 1:

Veredicto: Hipótesis rechazada. El análisis visual y estadístico de las distribuciones indica que no existe una correlación directa entre la expectativa de vida biológica de la raza y la velocidad con la que el animal es adoptado. Evidencia estadística: Estabilidad de medianas a través de las categorías de adopción más tempranas (0 a 3). Saturación en categoría 4 (promedio 15.35 años) que presenta una compresión extrema exactamente en los 16 años, reflejando una sobrepoblación de una raza específica con esa media biológica. Impacto de negocio: Los adoptantes no toman decisiones basadas en proyecciones genéticas a largo plazo ni en la longevidad estructural de la raza.

3.2.- Hipótesis 2: Impacto visual (Volumen de fotografías) vs. Velocidad de adopción

Pregunta: ¿El volumen de fotografías en el perfil de una mascota acelera estadísticamente su adopción?

Velocidad de Adopción (0 a 4)	Promedio de Fotos	Mediana de Fotos
0 (Mismo día)	3.32 fotos	3.0 fotos
1 (1 a 7 días)	3.73 fotos	3.0 fotos
2 (8 a 30 días)	4.07 fotos	3.0 fotos
3 (31 a 90 días)	4.62 fotos	4.0 fotos
4 (Más de 100 días / No adoptado)	3.32 fotos	3.0 fotos



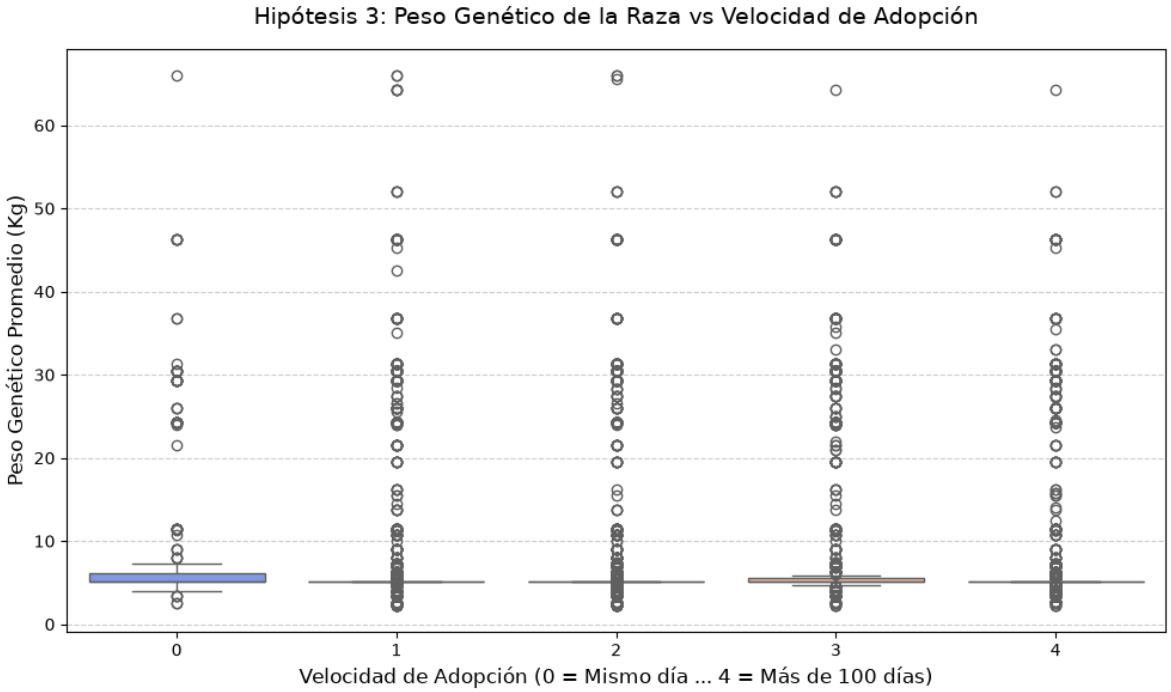
Conclusiones de la Hipótesis 2:

Veredicto: Hipótesis rechazada (correlación inversa). Un mayor volumen de fotografías en el perfil no acelera la adopción; por el contrario, los animales que más tardan en adoptarse acumulan una mayor cantidad promedio de fotos. Impacto de negocio (causalidad inversa operativa): La estadística refleja la operación interna del refugio y no la preferencia del adoptante. Un animal altamente demandado se adopta el mismo día sin requerir galerías extensas, mientras que el personal invierte mayor esfuerzo fotográfico subiendo nuevas imágenes en los animales estancados para intentar destrabar su adopción.

3.3.- Hipótesis 3: Preferencia de tamaño (Peso genético) vs. Velocidad de adopción

Pregunta: ¿Existe un sesgo de adopción medible hacia los animales genéticamente más pequeños frente a razas de tamaño grande o gigante?

Velocidad de Adopción (0 a 4)	Peso Promedio de la Raza (Kg)
0 (Mismo día)	9.63 kg
1 (1 a 7 días)	8.83 kg
2 (8 a 30 días)	8.54 kg
3 (31 a 90 días)	9.51 kg
4 (Más de 100 días / No adoptado)	7.53 kg



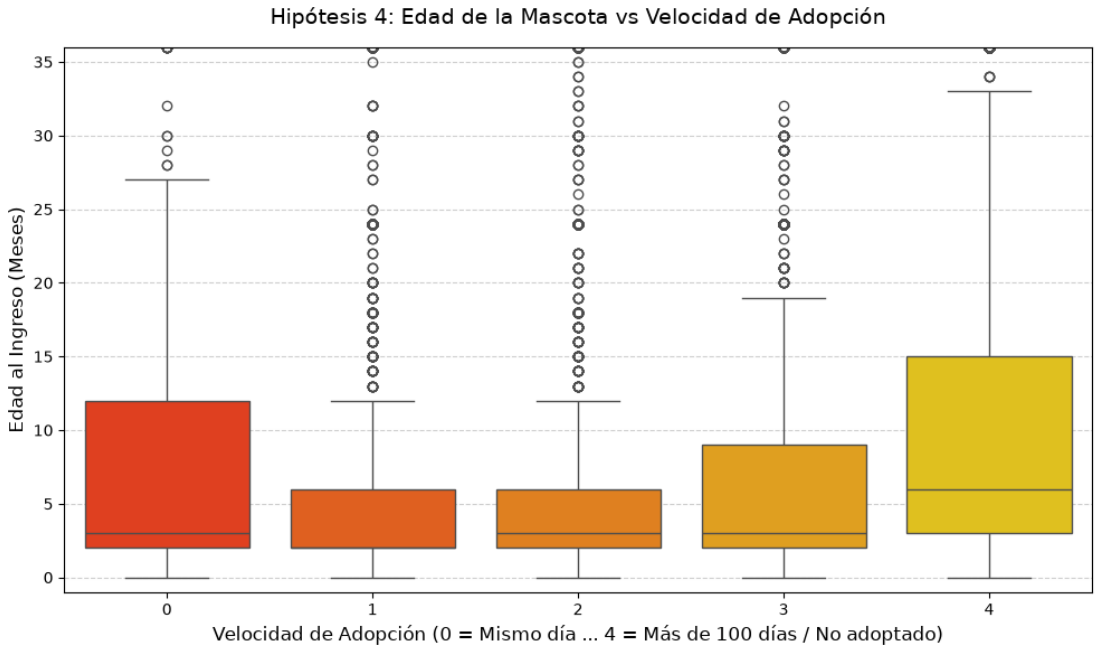
Conclusiones de la Hipótesis 3:

Veredicto: Hipótesis rechazada. El tamaño físico genético no actúa ni como ancla ni como acelerador de la adopción.
Evidencia estadística: Estabilidad absoluta de la mediana en la línea de los 5 kg. Los valores atípicos (razas grandes y gigantes) se distribuyen de manera uniforme tanto en las categorías de adopción inmediata como en las tardías.

3.4.- Hipótesis 4: Factor edad al ingreso (Punto de quiebre) vs. Velocidad de adopción

Pregunta: ¿Cuál es el punto de quiebre (en meses de edad) donde la probabilidad de adopción temprana cae drásticamente?

Velocidad de Adopción (0 a 4)	Edad Mediana (Meses)	Edad Promedio (Meses)
0 (Mismo día)	3.0 meses	10.45 meses
1 (1 a 7 días)	2.0 meses	8.49 meses
2 (8 a 30 días)	3.0 meses	8.82 meses
3 (31 a 90 días)	3.0 meses	10.19 meses
4 (Más de 100 días / No adoptado)	6.0 meses	13.67 meses



Conclusiones de la Hipótesis 4:

Veredicto: Hipótesis confirmada. La edad al momento del ingreso es el predictor individual más determinante de la velocidad de adopción, existiendo un punto de quiebre crítico a los 6 meses de edad, umbral a partir del cual el riesgo de estancamiento se dispara drásticamente.
Impacto de negocio: La "ventana dorada" de adopción orgánica ocurre entre los 2 y 5 meses de edad. El presupuesto de marketing y sesiones de fotografía debe focalizarse de manera proactiva en los animales que están cruzando el umbral de los 6 a 12 meses.